

带有协方差矩阵的卷积神经网络在人体运动识别中的应用^{*}

权威铭, 刘天一, 张 雷

(南京师范大学电气与自动化工程学院, 江苏 南京 210046)

摘 要: 目前, 深度学习已经在各种人体运动识别(HAR)任务中发挥了重要作用。但是, 由于运动数据具有时间序列和包含肢体动作的特殊性, 现有神经网络在进行卷积操作时会导致数据高度相关, 并且随着网络影响到下一层, 这限制了模型的识别效果。为此, 提出了一种带有协方差矩阵的改进卷积神经网络用于 HAR 场景, 通过矩阵变换搭建一种去相关的网络结构来消除相关性问题, 可以在网络表现不佳时替代现有的批量归一化(BN)层用于归一化数据。在 4 个 HAR 公共数据集上进行实验, 并与传统 CNN 和带有 BN 层的模型进行比较。实验结果表明, 对比此前的深度学习网络, 改进的神经网络有 1%~2% 的性能提升, 验证了该方法的有效性, 并将程序移植到了移动端进行实时运动识别。

关键词: 可穿戴传感器; 运动识别; 卷积神经网络; 协方差矩阵

中图分类号: TP212

文献标志码: A

doi: 10.3969/j.issn.1007-130X.2022.11.016

Application of convolutional neural network with covariance matrix in human activity recognition

QUAN Wei-ming, LIU Tian-yi, ZHANG Lei

(School of Electrical and Automation Engineering, Nanjing Normal University, Nanjing 210046, China)

Abstract: At present, deep learning has played an important role in various human activity recognition (HAR) tasks. However, the activity data has the particularity of time series and includes body movements. The existing convolutional neural network (CNN) will cause the data to be highly correlated when performing convolutional operations. As the network affects the next layer, the accuracy of network recognition is limited. In order to solve this phenomenon, this paper proposes an improved convolutional neural network with covariance matrix for HAR scenario. It builds a de-correlated network structure through matrix transformation to eliminate correlation problems. When the network performance is poor, the network can replace the existing BN layer to normalize data. The verification experiments are finished on four HAR public datasets. The proposed neural network is compared with traditional CNN model and BN layer model. The results show that the improved neural network is improved by 1% to 2% compared with the previous deep learning networks, which proves that the improved neural network is effective. Furthermore, the application is transplanted to the mobile terminal for real-time activity recognition.

Key words: wearable sensor; activity recognition; convolutional neural network; covariance matrix

^{*} 收稿日期: 2021-03-30; 修回日期: 2021-05-14

基金项目: 国家自然科学基金(61203237); 江苏省自然科学基金(BK20191371)

通信作者: 张雷(leizhang@njnu.edu.cn)

通信地址: 210023 江苏省南京市栖霞区文苑路 1 号南京师范大学电气与自动化工程学院

Address: School of Electrical and Automation Engineering, Nanjing Normal University, 1 Wenyuan Road, Qixia District, Nanjing 210023, Jiangsu, P. R. China

1 引言

科技的进步促使可穿戴设备飞速发展,这些设备正迅速改变着人们的生活及彼此互动的方式,并应用到了越来越多的领域中,如医疗、体育、教育和社交^[1,2]等。这些设备中的线性和非线性传感器记录的数据逐渐成为人工智能研究人员感兴趣的内容,对所采集的人体运动数据集通过卷积神经网络 CNN(Convolutional Neural Network)进行分类^[3]和训练,可以得到关于人体动作的识别模型。归功于传感器技术和机器学习的快速发展,人体运动识别已经得到了广泛关注。

由于内部和外部多种因素的影响,人体动作十分复杂,往往是多种动作的结合,提高人体运动的识别准确率一直是研究的难点。人体运动识别 HAR(Human Activity Recognition)的研究主要分为 2 个主流方向,分别为基于图像或视频分析的人体运动识别^[4]及基于传感器数据的人体运动识别^[5],其中前者能够清晰监测到人体当前所处的状态,识别准确率较高。孟勃等人^[6]提出了基于四元数时空卷积的人体姿态识别方法,基于彩色图像通道间的空间依赖性和环境颜色调整进行特征提取,提高了识别准确率。但是,基于图像或视频的识别模型对硬件要求较高,且应用场景较为单一,在大部分场合中无法做到便捷和安全,故需要开发一种更为安全可靠的识别方法。因此,基于可穿戴传感器数据的运动识别逐渐成为了研究重点。人体在运动过程中,可穿戴传感器会记录身体各个部位产生的加速度信号。由于相似动作或不同动作的干扰,这些带有时间序列的传感器数据包含了肢体动作的特殊性,输入到卷积神经网络后会产生相互关联,导致学习性能下降。

本文在运动识别的过程中通过新搭建的网络结构,在每层卷积之前使用协方差矩阵变换来消除数据之间的相关性,包括网络每一层的数据相关性和通道相关性。

2 深度学习网络在人体运动识别中的应用

2.1 基于深度学习的运动识别

随着计算机性能的迅速提高,深度学习已经应用到生产生活中的各个方面。卷积神经网络 CNN 可以自动从数据中提取特征,更加高效地实现分类,因此逐渐成为当前多个领域的研究热点^[7]。作为识别领域中的典型问题,人体运动识别 HAR 实质上是时间序列信号输入神经网络进行分类判别,得到带有活动类别的标签。将智能手机或可穿戴设备中的惯性传感器采集到的数据看作多维张量,送入深度卷积神经网络中提取特征并进行分类^[8]。具体过程是智能手机或者智能手表中携带的线加速度计、陀螺仪和距离传感器等均会在用户使用过程中记录当时的状态数据,人体运动识别算法将对这些数据进行有效的处理和分类,判断人体当时的运动状态及受试者生理健康情况等。相较于基于图像或视频的识别方法,上述方法不受当前所处位置的约束和复杂环境的影响,安全性高,数据采集方便,因此基于传感器的人体运动识别广泛应用在医疗健康、体育赛事和人机交互等众多新兴技术领域中。该方法的整体处理流程如图 1 所示,首先用户佩戴智能设备实时采集人体运动数据;然后对采集到的运动数据进行预处理;最后将数据送入卷积神经网络进行处理,自动识别出不同的运动类型。

2.2 卷积神经网络中的问题

在整个识别过程中,卷积是 CNN 的核心操作^[9],其过程可以简化为滤波器滑动遍历所有输入向量得到输出特征图。卷积操作实质上是计算上一层数据的加权和,而多个卷积核的依次操作会得到一个新的二维矩阵,其核心操作是卷积核的权值共享,即每个神经元使用相同的参数。目前在 HAR 任务上对卷积层的数据处理均使用归一化层,其中批量归一化 BN(Batch Normalization)是深度学习领域中广泛使用的减法和除法特征归一化方案^[10]。最初引入批量归一化是为了解决反向




Figure 1 Action recognition model based on neural network

图 1 基于神经网络的运动识别模型

传播过程中的梯度问题,BN 的使用加速了网络的训练过程,使得一般网络能快速收敛,但是对于小批量 batch 输入,归一化数据会产生偏差,导致过拟合现象,使测试精度下降。另一方面,在卷积神经网络中不同变量之间的直接和间接相关情况普遍存在^[11],此时在卷积层之间提取特征会导致直接的依赖关系,这种不同信道之间的关联(称之为干扰)会随着网络进行传递,影响到下一卷积层。本文在每层卷积操作之前均使用协方差矩阵变换以消除相关性并重构卷积层,将基于牛顿-拉夫逊算法的平方根倒数计算^[12]应用在深度学习中,作为一种去相关的网络结构来消除人体运动识别神经网络模型中每一层的相关性问题。

本文使用带有协方差矩阵的重构卷积层来代替带有归一化层的卷积结构,以此来构建深度神经网络。与 LeCun 等人^[13]搭建的卷积神经网络不同,本文网络中的每一层都是自上而下的,通过寻求特征映射(而不是输入)与学习滤波器的卷积来生成输入信号。为了验证本文网络的有效性,本文在多个使用较多的公共基准数据集上进行对比实验。实验结果表明,本文网络相较于其它对比网络,在没有增加任何额外成本的情况下进一步提高了性能和学习效率,测试精度比具有相同参数量的训练网络的精度更高。

3 相关工作

HAR 作为一种典型的分类任务,从按时间排序的人体活动中识别出人体动作,根据识别误差不断更新网络。在整个分类任务中,特征提取是最重要的一个环节。早期研究人员使用傅里叶变换和小波变换^[14]对运动加速产生的波形进行变换,但这种方法由于识别准确率不高且非线性拟合不够而逐渐被淘汰。卷积神经网络近些年在模式识别中应用非常广泛,已成为机器学习领域的主流方法之一。从 20 世纪末开始,计算机在数据处理中发挥了越来越重要的作用,从决策树^[15]、支持向量机^[16]和朴素贝叶斯^[17],再到现在的卷积神经网络(CNN)^[18,19],从人工提取特征到现在的计算机自动提取特征,各种学习方法都发挥了重要作用。

在图像识别任务中,将从图像中提取的特征转化为多维向量送入到神经网络中进行分类,其分类效果受特征影响较大。深度神经网络能够从运动数据中提取到更有意义的特征,通过大规模数据训练出的神经网络能够进行更有针对性的识别,这给

人体运动识别带来了新的研究方向。Zeng 等人^[18]在 2014 年首次将 CNN 技术应用于 HAR,提出了一种用于运动识别的自动提取特征的方法,并通过实验证明了其有效性。这一方法的使用,确立了基于卷积神经网络进行运动识别的研究方向。为了继续提高识别准确率,此后很多研究工作的重点放在了改进卷积神经网络结构上。Jiang 等人^[20]将加速度计和陀螺仪的信号序列组合成一幅活动图像,使深度卷积神经网络能够自动从活动图像中学习最优特征。Hammerla 等人^[21]在数千个使用随机采样模型配置的识别实验中,探索每种模型在 HAR 中的适用性,并使用 Fanova 框架探索了超参数设置对网络精度的影响。

计算能力的提升使许多机器学习方法再次启用并涌现出很多相关改进方法。Teng 等人^[22]采用了一种带有局部损失的分层卷积神经网络,以减小全局损失和占用内存的影响。HAR 中引入批量归一化、梯度中心化^[23]和注意力机制等优化方法进一步提高了分类性能,其中批量归一化用来改进随机梯度下降,加快网络训练和收敛速度,同时控制梯度爆炸和防止梯度消失。Golestani 等人^[24]使用循环神经网络作为一种新的特征提取方案应用在运动识别中。本文在多种改进卷积神经网络方法的启发下,将带有协方差矩阵的卷积神经网络应用在人体运动识别上,以提高神经网络在公共数据集上的识别准确率。

4 网络结构

本节首先介绍带有协方差矩阵的网络卷积层,其网络结构基于传统 CNN 模型。近年来针对神经网络出现了各种不同的改进方法,本文从协方差矩阵相关性变化中得到启发,在每层卷积之前对数据张量进行矩阵变换以消除相关性。在 HAR 原始训练数据输入张量分为多个通道的时间序列信号的前提下,需要对数据进行预处理。本文对公共数据集基于滑动窗口策略进行切割处理,使信号按照时间序列被分割成多个相同大小的多维向量,以便网络进行处理。

4.1 卷积神经网络

卷积神经网络 CNN 是由全连接前馈神经网络发展而来的,是机器学习理论的一个分支,在图像识别和分类领域应用广泛。二维卷积神经网络主要由卷积层(Convolution Layer)、池化层(Pooling Layer)及全连接层(Fully-connected Layer)组成,通过这些层的耦合叠加,构建出一个完整的卷积神经网络,如图 2 所示。卷积层作为网络的核心




Figure 2 Convolutional neural network

图 2 卷积神经网络

层,其激活函数一般采用 ReLU 进行非线性操作,从输入数据中提取特征,该层产生了网络中大部分的计算量,但可以通过局部连接和权值共享来降低参数数量的同时提高运算速度。最后全连接层作为输出层实现识别和分类,其激活函数一般采用 Softmax。

卷积神经网络在处理传感器数据时,一般采用二维卷积操作,其操作公式如式(1)所示:

$$B(i, j) = \sum_{m=0, n=0} K(m, n) * A(i-m, j-n) \quad (1)$$

其中, A 表示上一层矩阵, $K(\cdot, \cdot)$ 表示卷积核, $m \times n$ 表示卷积核大小, $i \times j$ 表示卷积操作输入的大小, $m \leq i, n \leq j$, B 表示卷积后的特征输出。应用在神经网络时卷积层公式如式(2)所示:

$$\text{output} = f\left(\sum_i W_i * X_i + b_i\right) \quad (2)$$

其中, output 表示下一层输入。每一个卷积核 W_i 对应一个偏置 b_i , 每层都通过卷积核与输入 X_i 相乘后,再由激活函数进行非线性化得到上一层的特征图。池化层不改变网络的特征向量,只减少参数

量,其输出特征可能是由多个卷积核学习不同输入特征的组合。利用损失函数得到实际输出和期望输出之间的误差,并通过梯度反向传播来更新卷积核的参数,因此对于 CNN 而言,每层的结构和参数都会影响数据处理效率。


4.2 改进的卷积神经网络

对于复杂的人体运动来说,可穿戴传感器得到的数据往往存在很强的特征相关性,神经网络的卷积操作更是加深了这一相关性。对于每层神经网络,其基本公式简化后如式(3)所示:

$$f(X) = W * X + b \quad (3)$$

其中,矩阵乘法 $W * X$ 中的 W 为二维卷积核,卷积核在数据上进行卷积操作时依次滑动,用常用函数 $\text{im2col}()$ 可以将原数据转化为以列的方式进行操作。在图 3 中可以看到,处理后的 X 具有高度列相关性,这会在接下来的卷积过程中造成误差并违反最优条件,且通常使用批量归一化也无法解决这一问题。

网络的每一层通常会有多个输入通道和多个内核,在每个通道中调用 $\text{im2col}()$ 函数来优化卷

Figure 3 Matrix operation of function $\text{im2col}()$ 图 3 函数 $\text{im2col}()$ 矩阵操作

积运算,本质上并未改变数据结构,即将卷积核感受野对应的区域转化成1行(列)来存储,将二维结构数据转化为一维结构,通过水平合并每个通道的数据矩阵来构建完整的层输入数据,实现优化运算,缩短内存访问时间。最后合并所有内核以获得 $\mathbf{W}$,用矩阵矢量乘法计算 $\mathbf{X}$ 和 $\mathbf{W}$ 得到输出 $\mathbf{Y}$ 。

本文搭建的卷积神经网络的核心操作是使用协方差矩阵变换,通过卷积神经网络重建每一层的输入以便提取新特征,以此来逆校正数据之间的相关性。在前向计算过程中,协方差矩阵对于数据精度是有益的,并且在梯度下降训练中也可以更新校正后的梯度值。

对于数据矩阵 $\mathbf{X}_{M,N}$,其中, N 是样本数, M 是特征数, $\mathbf{Cov}$ 是随机张量之间协方差的一种矩阵表示,利用对称正定矩阵来表示相关关系,此时计算公式如式(4)所示:

$$\mathbf{Cov} = \frac{1}{N}(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^T \quad (4)$$

协方差矩阵一般用来计算数据的相关性,利用矩阵的可逆性来消除卷积神经网络中数据的相关性。对于矩阵逆运算,首先计算协方差矩阵 $\mathbf{D}$ 的近似平方倒数,如式(5)所示:

$$\mathbf{D} = \mathbf{Cov}^{-\frac{1}{2}} \quad (5)$$

然后将其乘以居中向量 $(\mathbf{X} - \boldsymbol{\mu}) * \mathbf{D}$ 。在某种意义上,协方差矩阵的转换可以消除数据方向和通道方向之间的相关影响。如果计算过程理想化,则转换后的数据具有单位矩阵作为协方差的恒等矩阵式,如式(6)所示:

$$\begin{aligned} \mathbf{D}^T(\mathbf{X} - \boldsymbol{\mu})^T(\mathbf{X} - \boldsymbol{\mu}) * \mathbf{D} = \\ \mathbf{Cov}^{-\frac{1}{2}} * \mathbf{Cov} * \mathbf{Cov}^{-\frac{1}{2}} = \mathbf{I} \end{aligned} \quad (6)$$

但是,在实际运算过程中 $\mathbf{D}$ 往往利用式(7)所示的计算方法求得:

$$\mathbf{D} \approx (\mathbf{Cov} + \epsilon * \mathbf{I})^{-\frac{1}{2}} \quad (7)$$

其中, $\epsilon * \mathbf{I}$ 用来提高稳定性。然后,把协方差矩阵应用在卷积过程中,将处理过的数据乘以卷积核 $\mathbf{W}$,通过矩阵乘法构建整个卷积层用以消除相关性,具体如式(8)所示:

$$\mathbf{Y} = (\mathbf{X} - \boldsymbol{\mu}) * \mathbf{D} * \mathbf{W} + \mathbf{b} \quad (8)$$

将第 i 层中的协方差运算表示为 $\mathbf{D}_i$,下一卷积层的输入 $\mathbf{X}_{i+1}$ 如式(9)所示:

$$\mathbf{X}_{i+1} = g_i(\mathbf{W}_i * \mathbf{D}_i * \mathbf{X}_i) \quad (9)$$

其中, $\mathbf{X}_i$ 是来自第 i 层的输入数据, $\mathbf{D}_i$ 是在该输入上进行协方差矩阵运算, $\mathbf{W}_i$ 是每一卷积层中的权重矩阵, $g_i()$ 是激活函数,使网络具有非线性分类的能

力,本文采用ReLU激活函数,如式(10)所示:

$$g(x) = \max(0, x) \quad (10)$$

重新搭建的卷积层中改进了反向传播更新梯度方式,每一层的卷积层重构会引起权重变化,用 $\mathbf{W}^\#$ 来标识新卷积层中权重矩阵, $\mathbf{Y}$ 表示卷积之后的结果,可以推出式(11)和式(12):

$$\mathbf{X} * \mathbf{W} = \mathbf{X} * \mathbf{D} * \mathbf{W}^\# = \mathbf{Y} \quad (11)$$

$$\mathbf{W}^\# = \mathbf{D}^{-1} * \mathbf{W} \quad (12)$$

其中, $\mathbf{W}^\#$ 是加入协方差后的卷积层权重值,此时对于损失函数 $Loss$ 反向求导后如式(13)所示:

$$\frac{\partial Loss}{\partial \mathbf{W}^\#} = \frac{\partial Loss}{\partial \mathbf{Y}} * \frac{\partial \mathbf{Y}}{\partial \mathbf{W}^\#} = (\mathbf{X} * \mathbf{D})^T * \frac{\partial Loss}{\partial \mathbf{Y}} \quad (13)$$

对于加入协方差后的一次梯度更新迭代如式(14)所示:

$$\mathbf{W}_n^\# = \mathbf{W}^\# - \alpha \frac{\partial Loss}{\partial \mathbf{W}^\#} \quad (14)$$

其中, $\mathbf{W}_n^\#$ 表示带有协方差的卷积神经网络在一次迭代梯度更新后的数据矩阵, α 表示学习率。结合式(5)、式(11)和式(12),可以得到关于卷积层迭代权重,更新情况如式(15)所示:

$$\begin{aligned} \mathbf{W}_n^\# = \mathbf{W}^\# - \alpha \mathbf{D}^2 * \mathbf{X}^T * \frac{\partial Loss}{\partial \mathbf{Y}} = \\ \mathbf{W}^\# - \alpha \mathbf{Cov}^{-1}(\mathbf{X}^T * \frac{\partial Loss}{\partial \mathbf{Y}}) \end{aligned} \quad (15)$$

5 实验与结果分析

本节首先介绍本文实验所用的数据集,然后介绍实验过程及参数设置,最后给出实验结果并进行分析。

5.1 实验数据

由于本文数据集都是通过受试者携带传感器获得,这些数据集根据采集情况侧重点各有不同。为了验证本文所提网络的准确性,本文使用了被广泛认可的4种HAR公共数据集,在4个数据集上使用相同的网络结构,然后通过调整超参数使测试精度达到预期。本文所用精度指所有样本中预测正确的样本占全部样本的比例。本文所用的4个公共数据集分别为UCI-HAR数据集^[25]、PAMAP2数据集^[16]、UniMiB SHAR数据集^[26]和WISDM数据集^[27]。

(1) UCI-HAR数据集的测试对象是年龄在19~48岁的30位志愿者,每个人在腰部均戴有智能手机(Samsung Galaxy S II),共采集6种活动,包括散步、上楼、躺下等简单动作。采集频率设置

为 50 Hz, 捕获手机中的三轴线加速度和角速度。视频记录整个实验过程并手动标记数据类型, 后期对加速度计和陀螺仪的传感器信号进行预处理, 使用宽度为 128, 在 2.56 s 和 50% 重叠的窗口中滑动采样。数据集随机分为 2 组, 70% 的数据用于训练, 30% 的数据用于测试。

(2) PAMAP2 数据集一共包含 12 种体育活动, 属于体育活动监测类型数据集。按照不同的要求, 受试者带有 3 个惯性测量单位和心率监测器, 在主要部位如手腕、胸部和脚踝放置传感器, 分别进行 12 种不同的生活运动 (如走路、跑步等) 以获取身体运动数据, 采样频率为 100 Hz。该数据集可用于活动识别和强度估计。本文使用 5.1 s 的滑动窗口对传感器数据进行切片, 使重叠率在 70% 左右, 并将数据集随机切割成 80% 的训练数据和 20% 的测试数据。

(3) UniMiB SHAR 是近些年专为人类活动识别和跌倒检测而采集的数据集, 数据主要来自受试者所携带的加速度计和陀螺仪, 旨在挖掘传感器在医疗领域的新作用。数据采集过程由 30 位志愿者参与, 一共采集了 11 771 个样本。本文实验选择其中的 AF-17 进行识别任务, 其中包含了 9 种日常生活活动和 8 种跌倒类型共 17 类。这 17 类识别任务活动类型相差不大, 能用来检测模型的性能。

(4) WISDM 是使用智能手机和智能手表采集到的运动数据集, 该数据集以 20 Hz 的采集速率对 51 位测试对象分别进行了 18 min 的日常生活活动采集。该数据集还包含了加速度计和陀螺仪的传感器数据, 这些带有时间序列的数据用不同的活动标记区分开, 并使用滑动窗口方法将其转换为带标签的分类活动, 使数据可以用于构建和评估生物测定以及相关识别研究。WISDM 数据集一共包含 1 098 213 个样本, 其中 70% 用于训练, 剩余 30% 用于测试。数据集可以在 UCI 机器学习数据储存库获得。

WISDM 和 UCI-HAR 数据集分属不同实验室采集, 使用不同的样本采集方式, 且侧重点不同。2 个数据集都是 6 分类, 包含走路、上下楼、坐和站立等简单动作类型。本文通过这 2 个数据集上的对比实验结果来分析本文所提网络对相似动作的识别精度和网络可迁移性。

PAMAP2 和 UNIMIB 数据集, 分别是 12 和 17 分类任务, 不但包括上述数据集中的简单动作, 还包含开关门、清理房间、踢足球和楼梯跌倒等相对复杂的动作。本文通过这 2 个数据集上的实验结果来判断本文所提网络对复杂动作的识别能力

和泛化能力。

5.2 实验过程

本文的网络结构在每个公共数据集上均实验 3 次, 分别为带有批量归一化层的卷积神经网络 (BN-CNN)、带有协方差矩阵的卷积神经网络 (Cov-CNN) 和基准卷积神经网络 (CNN)。实验中, 网络均由 3 层主卷积层组成, 激活函数均为 ReLU, 在第 2 层卷积操作后加步长为 2 的最大池化层 (Maxpooling), 全连接之前对数据进行平均池化, 以减少网络的参数量, 用以加速计算, 全连接通过一个附加的 Softmax 激活函数进行最后的分类。基准 CNN 流程为 $C(i) \times 3 \rightarrow FC \rightarrow Softmax$, 其中 $C(i)$ 表示具有 i 个滤波器的卷积层, 本文中每层数量分别设置为 (64, 128, 256), FC 的连接数取决于来自堆叠卷积层扁平化特征向量的维数, 每组实验进行 200 轮次 (Epoch) 学习, 每个 Epoch 均表示所有的数据完成了一次前向计算和反向传播。学习率均设置为 0.000 1。使用 ADAM 算法进行梯度优化, 该算法内存要求小, 计算高效, 适用于稀疏梯度求解, 被广泛应用于各种网络优化。本文实验在 Ubuntu 服务器上运行, CPU 为 Intel Core i7 6850 K, 所用计算显卡为 NVIDIA GTX 3090, 24 GB 显存。

5.3 实验结果

在整个实验中, 本文通过调整超参数来寻找最优值, 包括调节滤波器尺寸 K 、卷积核数量和卷积步长等, 不同数据集对应的最优超参数也不同。不同于固定尺寸的图像数据, 传感器数据相对不规则, 滤波器和输入向量之间的匹配也会有所不同。对于 WISDM 数据集和 UCI-HAR 数据集, 滤波器尺寸 $K = (3, 1)$ 时往往能取得最佳性能; 对于 UniMiB SHAR 等复杂数据集, 需要增大 K 值才能获得更好的性能, 第 1 层卷积中 $K = (3, 1)$, 后面 2 层中 $K = (6, 1)$, 对于 PAMAP2 数据集 3 层卷积中均设置 $K = (6, 1)$ 。

基准 CNN 网络 (CNN)、带有批量归一化层的卷积神经网络 (BN-CNN) 及带有协方差矩阵的卷积神经网络 (Cov-CNN) 在 4 个数据集上以及在不同 Epoch 时的实验结果如表 1 所示。可以看到, 本文搭建的网络收敛速度明显最快, 且最优值在前几次迭代时就已经出现。相似动作数据之间固有的相关性使运动数据识别相对复杂, 使用带有协方差的多层特征提取器与其他方法相比更容易消除相关性影响和提升网络性能。

图 4 显示了在 4 个数据集上 2 种网络的测试

Table 1 Experimental results of different networks on 4 datasets

表 1 不同网络在 4 个数据集上的实验结果

数据集	网络	Epoch				
		1	5	10	30	100
UCI-HAR	CNN	77.40	87.34	89.03	90.53	93.01
	BN-CNN	78.93	91.07	92.16	93.07	93.51
	Cov-CNN	79.03	92.33	93.24	94.46	94.91
PAMAP2	CNN	61.18	80.22	80.61	80.61	80.61
	BN-CNN	78.20	83.44	86.66	89.30	89.41
	Cov-CNN	80.81	90.96	92.26	92.26	92.87
UniMiB SHAR	CNN	64.45	68.41	71.66	72.77	72.87
	BN-CNN	66.70	71.34	73.45	74.61	75.03
	Cov-CNN	66.03	72.62	74.58	75.08	75.79
WISDM	CNN	43.87	90.29	93.35	95.72	95.78
	BN-CNN	81.87	93.47	94.46	96.60	96.84
	Cov-CNN	82.64	94.32	96.87	98.15	98.97




Figure 4 Test accuracy curves on different datasets

图 4 不同数据集上的测试精度曲线

精度曲线。可以看出,在不同数据集上本文网络的测试精度均不低于带有 BN 层的网络;从整体上看虽然 2 种网络的收敛速度相近,但本文提出的网络在多个 Epoch 下稳定性更好,且 200 轮次内本文网络识别精度略胜于相同条件下的基于批量归一化卷积神经网络。

在深度卷积神经网络的学习过程中,测试精度可能出现小幅度震荡或性能衰减,这一般是由标签噪声引起的。尽管传感器数据在预处理阶段已经按照时间被严格划分到了相应批次,但是与 CIFAR-10 或 MINIST 之类噪声很少的图像数据集不同,含有运动特征的数据流必须经过滑动窗口分

段后才能用于 CNN,在获取相邻人体运动的数据特征时,滑动窗口在过渡区间不可避免地包含了来自 2 个活动的数据,此时一般根据这些窗口的比例将数据标记为单一动作,因此导致整体数据集出现了标签噪声。因此,在网络测试过程中,当某一批次数据包含太多此类交叉窗口时,不可避免地会出现性能振荡现象。

重新构建卷积层使 HAR 性能得到了提升,且对卷积层结构改变的同时,网络的训练和测试时间也会发生变化,本文在 UniMiB SHAR 数据集上进行实验,以探究不同网络对数据的处理速度。首先基准 CNN 和带有协方差矩阵的卷积神经网络

在相同超参数的情况下进行训练,然后获取训练和测试过程中所用时间,表2中给出了不同网络在200个 *Epoch* 训练和测试时的平均使用时间。结果显示,新搭建的网络的测试时间变化很小,但是训练时间明显增加,这是由于训练过程中协方差矩阵变换需要时间来计算和更新梯度值。

Table 2 Test time and training time of different networks on UniMiB SHAR dataset

表2 不同网络在 UniMiB SHAR 数据集上的测试与训练时间

网络	训练时间/s	测试时间/s
CNN	3.023	0.325
Cov-CNN	11.814	0.359

目前,智能手机中集成了越来越多的传感器,成为了可穿戴设备的理想型,已应用于多种使用场景。本文网络在此前基础上加以改进,不但可以在公共数据集上执行识别任务,还可以将训练好的网络移植到移动终端进行实时运动识别,并开发了基于智能手机传感器的实时 HAR 应用程序。该应用程序已经部署在 Android 客户端,实验设备是基于 Android 10.0 的 Huawei Honor 20i 智能手机。具体步骤如下:首先,将带有协方差矩阵的卷积神经网络在 WISDM 数据集上进行训练,在200个 *Epoch* 后确定网络参数,用权重的形式保存计算图,得到关于权重的结构化数据文件(Protobuf 数据存储结构);然后,将保存的 BP 文件加载到 PyTorch Mobile 中执行;最后,在 Android studio 部署打包为可执行运动识别的应用程序。该应用程序能够以智能设备携带的内置加速度传感器获得的数据作为输入,根据本地模型进行实时人体运动识别,例如上楼、下楼等。应用程序用户界面的屏幕截图如图5所示,识别结果包括识别出的动作类型和相应概率。对于实时运动检测的时间,本文使用 TFLite 工具来检测带有协方差矩阵的卷积神经网络对人体运动的推理速度,结果显示对每个动作的平均推断时间在 169 ms~205 ms。

此外,为了证明本文网络相比于普通卷积神经网络的优越性,将带有协方差矩阵的卷积神经网络和基准 CNN 在 WISDM 数据集和 PAMAP2 数据集上的识别结果,以混淆矩阵的形式可视化。混淆矩阵广泛用于衡量分类模型的分类结果,以可视化矩阵的形式将测试结果按照真实类别与预测类别进行汇总,能直观地看出分类效果,其中每一列代表网络预测类别,每一行代表实际类别。识别结果如图6和图7所示。




Figure 5 Recognition interface of Android mobile phone
图5 基于安卓手机的识别界面




Figure 6 Confusion matrix on WISDM dataset
图6 WISDM 数据集上的混淆矩阵

从图6和图7可以看出,在6分类的 WISDM 数据集上,分类误差主要集中在上楼和走路的动作识别过程中,在较复杂分类的 PAMAP2 数据集上也出现了走路动作识别错误的情况,这可能是由于这些运动的加速度和幅度相似更容易触发同一传感器所导致的;网络对复杂动作分类效果较好,且应用协方差矩阵的网络识别准确率有 1%~2% 的提升。可见,对基于可穿戴传感器的 HAR 任务来说,本文提供了一种新的数据处理方法,在对数据进行批量归一化后测试效果依旧不佳的情况下,可以考虑使用带有协方差矩阵的卷积神经网络。



Figure 7 Confusion matrix on PAMAP2 dataset

图7 PAMAP2数据集上的混淆矩阵

6 结束语

在已有人体运动识别研究的基础上,本文提出了一种带有协方差矩阵的卷积神经网络,该网络的最大特点在于对数据进行卷积操作之前进行了不相关处理,增强了卷积过程中对特征的提取效果。在多个基准数据集上比较了本文网络及基准卷积神经网络的分类效果,实验结果表明:本文网络通过解决数据之间相关性的问题,在人体运动识别上取得了较好的成绩,带有协方差矩阵的卷积神经网络在一定程度上改善了卷积神经网络在训练过程中的收敛性,在训练初期本文所提网络能够更快地达到稳定,在第20个 *Epoch* 时基本收敛到最优值。本文网络在经过参数调整后可以在不同数据集上取得良好的识别效果,具有较好的泛化能力。下一步会将网络应用在其它运动识别任务中,以便获得更好的性能提升。

参考文献:

- [1] Sun Zi-wen, Sun Xiao-wen. A human fall detection algorithm based on acceleration sensor[J]. Computer Engineering & Science, 2017, 39(2): 330-335. (in Chinese)
- [2] Wang Tian, Li Qing-wu, Liu Yan, et al. Abnormal human body behavior recognition using pose estimation [J]. Chinese Journal of Scientific Instrument, 2016, 37(10): 2366-2372. (in Chinese)
- [3] Lara O D, Labrador M A. A survey on human activity recognition using wearable sensors[J]. IEEE Communications Surveys & Tutorials, 2012, 15(3): 1192-1209.
- [4] Ke S R, Thuc H L U, Lee Y J, et al. A review on video-based human activity recognition[J]. Computers, 2013, 2(2): 88-131.
- [5] Zheng Zeng-wei, Du Jun-jie, Huo Mei-mei, et al. Review of human activity recognition based on wearable sensors [J]. Journal of Computer Applications, 2018, 38(5): 1223-1229. (in Chinese)
- [6] Meng Bo, Liu Xue-jun, Wang Xiao-lin. Human body action recognition based on quaternion spatial-temporal convolutional neural network[J]. Chinese Journal of Scientific Instrument, 2017, 38(11): 2643-2650. (in Chinese)
- [7] Zhu Yu, Zhao Jiang-kun, Wang Yi-ning, et al. A review of human action recognition based on deep learning[J]. Acta Automatica Sinica, 2016, 42(6): 848-857. (in Chinese)
- [8] Xi R, Hou M, Fu M, et al. Deep dilated convolution on multi-modality time series for human activity recognition[C]//Proc of 2018 International Joint Conference on Neural Networks, 2018: 1-8.
- [9] Li Yan-dong, Hao Zong-bo, Lei Hang. Survey of convolutional neural network[J]. Journal of Computer Applications, 2016, 36(9): 2508-2515. (in Chinese)
- [10] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//Proc of International Conference on Machine Learning, 2015: 448-456.
- [11] Feizi S, Marbach D, Médard M, et al. Network deconvolution as a general method to distinguish direct dependencies in networks[J]. Nature Biotechnology, 2013, 31(8): 726-733.
- [12] Pizano-Escalante L, Parra-Michel R, Castillo J V, et al. Fast bit-accurate reciprocal square root[J]. Microprocessors and Microsystems, 2015, 39(2): 74-82.
- [13] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.
- [14] Tamura T, Sekine M, Ogawa M, et al. Classification of acceleration waveforms during walking by wavelet transform [J]. Methods of Information in Medicine, 1997, 36(4/5): 356-359.
- [15] Casale P, Pujol O, Radeva P. Human activity recognition from accelerometer data using a wearable device[C]//Proc of Iberian Conference on Pattern Recognition and Image Analysis, 2011: 289-296.

- [16] Anguita D, Ghio A, Oneto L, et al. Human activity recognition on smartphones using a multiclass hardware-friendly support vector machine[C]//Proc of International Workshop on Ambient Assisted Living, 2012: 216-223.
- [17] Kuncheva L I. On the optimality of Naive Bayes with dependent binary features[J]. Pattern Recognition Letters, 2006, 27(7): 830-837.
- [18] Zeng M, Nguyen L T, Yu B, et al. Convolutional neural networks for human activity recognition using mobile sensors [C]//Proc of the 6th International Conference on Mobile Computing, Applications and Services, 2014: 197-205.
- [19] Zhou Fei-yan, Jin Lin-peng, Dong Jun. Review of convolutional neural network[J]. Chinese Journal of Computers, 2017, 40(6): 1229-1251. (in Chinese)
- [20] Jiang W, Yin Z. Human activity recognition using wearable sensors by deep convolutional neural networks[C]//Proc of the 23rd ACM International Conference on Multimedia. 2015: 1307-1310.
- [21] Hammerla N Y, Halloran S, Plötz T. Deep, convolutional, and recurrent models for human activity recognition using wearables[C]//Proc of the 25th International Joint Conference on Artificial Intelligence, 2016: 1533-1540.
- [22] Teng Q, Wang K, Zhang L, et al. The layer-wise training convolutional neural networks using local loss for sensor-based human activity recognition[J]. IEEE Sensors Journal, 2020, 20(13): 7265-7274.
- [23] Yong H W, Huang J Q, Hua X S, et al. Gradient centralization: A new optimization technique for deep neural networks[C]//Proc of European Conference on Computer Vision, 2020: 635-652.
- [24] Golestani N, Moghaddam M. Human activity recognition using magnetic induction-based motion signals and deep recurrent neural networks[J]. Nature Communications, 2020, 11(1): 1-11.
- [25] Reiss A, Stricker D. Introducing a new benchmarked dataset for activity monitoring[C]//Proc of the 16th International Symposium on Wearable Computers, 2012: 108-109.
- [26] Micucci D, Mobilio M, Napolitano P. UniMiB SHAR: A dataset for human activity recognition using acceleration data from smartphones[J]. Applied Sciences, 2017, 7(10): 1101-1103.
- [27] Kwapisz J R, Weiss G M, Moore S A. Activity recognition using cell phone accelerometers[J]. ACM SIGKDD Explorations Newsletter, 2011, 12(2): 74-82.

附中文参考文献:

- [1] 孙子文, 孙晓雯. 基于加速度传感器的人体跌倒检测方法[J]. 计算机工程与科学, 2017, 39(2): 330-335.
- [2] 王恬, 李庆武, 刘艳, 等. 利用姿势估计实现人体异常行为识别[J]. 仪器仪表学报, 2016, 37(10): 2366-2372.
- [5] 郑增威, 杜俊杰, 霍梅梅, 等. 基于可穿戴传感器的人体活动识别研究综述[J]. 计算机应用, 2018, 38(5): 1223-1229.
- [6] 孟勃, 刘雪君, 王晓霖. 基于四元数时空卷积神经网络的人体行为识别[J]. 仪器仪表学报, 2017, 38(11): 2643-2650.
- [7] 朱煜, 赵江坤, 王逸宁, 等. 基于深度学习的人体行为识别算法综述[J]. 自动化学报, 2016, 42(6): 848-857.
- [9] 李彦冬, 郝宗波, 雷航. 卷积神经网络研究综述[J]. 计算机应用, 2016, 36(9): 2508-2515.
- [19] 周飞燕, 金林鹏, 董军. 卷积神经网络研究综述[J]. 计算机学报, 2017, 40(6): 1229-1251.

作者简介:



权威铭(1996-), 男, 安徽宿州人, 硕士生, 研究方向为深度学习、传感器技术和人工智能理论。E-mail: 2081448676@qq.com

QUAN Wei-ming, born in 1996, MS candidate, his research interests include deep learning, sensor technology, and artificial intelligence theory.



刘天一(1996-), 男, 江苏扬州人, 硕士生, 研究方向为人体运动识别、计算机视觉和机器学习。E-mail: 2750336871ty@gmail.com

LIU Tian-yi, born in 1996, MS candidate, his research interests include human activity recognition, computer vision, and machine learning.



张雷(1979-), 男, 河南周口人, 博士, 副教授, 研究方向为机器学习和信号处理。E-mail: leizhang@njnu.edu.cn

ZHANG Lei, born in 1979, PhD, associate professor, his research interests include machine learning and signal processing.